CampusClaw Freebird
系统功能与调用验证报告

日期：2026 年 10 月 27 日（北京时间）| 受检代码提交：7402c56be57c80dd85b929edb13a3f26b099da92 | 自动化测试：46 项通过

Git 仓库：https://github.com/ricemin0216/campusclaw.git。上述代码提交已写入 main；本 PDF 作为后续文档提交加入仓库。

项目简介：面向班级的 AI 学习平台。教师组合角色提示词、教学技能、课程材料和受控 MCP 工具；学生在私有会话中选择智能体及技能，获取可追问、带资料引用和工具状态的学习支持。主要组件为 Flask、SQLite 元数据、MySQL 关键词检索、Qdrant 向量库与 OpenAI 兼容模型接口。

一、五项能力评估

要求	结论	实现证据与边界
1. 多个 AI 应用	基本满足	A/B 班预置学习助手、教师可创建多个智能体；另有资料 AI 问答入口。
2. 提示词模板	部分满足	可编辑智能体角色提示词，并在每轮拼入 system；没有独立模板库、变量与版本管理。
3. 知识库检索	满足	材料切片后支持关键词、向量和混合检索；会话限本班及智能体绑定材料。
4. 内置及上传 Skill	满足（限定格式）	每班六项预置技能；教师 API 接受 UTF-8 单文件或文本；网页当前用文本框提交。
5. 外部工具与 MCP	满足（限定方式）	可登记服务器、握手、发现、调用与审计；通用模型自主 tool calling 尚未实现。

代码依据：app/db.py:269-358；app/__init__.py:789-812, 907-983, 1199-1261；app/retrieval.py:640-680；app/mcp_client.py:63-140。

二、五个需验证的问题

1. 每轮传给 LLM 的参数、提示词及返回内容

需区分会话流式提问、AI 资料问答、关键词问答三条路径。关键词问答只组织命中摘录，完全不调用聊天模型。其余两条均通过 OpenAI 兼容 Chat Completions。

路径	应用显式传入模型的参数	模型与 API 返回
会话流式	model=CHAT_MODEL；messages=[system, 最多 5 条既往消息, 本轮 user]；temperature=0.1；max_tokens=600；stream=True。	读 choices[0].delta.content；前端接收 SSE meta、delta，正常结束应为 done。
AI 资料问答	同一 model/temperature/max_tokens；messages 为固定 system + 含问题及最多 5 个证据片段的 user；不传 stream。	读 choices[0].message.content.strip()；API 返回 answer 与服务端构造的 citations。
关键词问答	无聊天模型请求。	API 返回 answer、keywords、citations。

会话 system 包含智能体可编辑的角色提示词、当轮命中 Skill 的名称与 description、引用规则及固定边界规则，因此角色提示词每轮都会传递。user 包含问题、最多 4 个资料片段（每片最多 800 字）及成功 MCP 输出（每项最多 1000 字）。完整模板文件、API 密钥、MCP Bearer 令牌和工具 schema 不在 messages 中；代码未传 tools/tool_choice。

历史处理：端点先保存本轮 user，再取最近 6 条记录，构造消息时去掉重复的本轮 user；故实际通常是最多 5 条既往消息加本轮问题，每条既往消息最多 500 字。

代码依据：app/tutoring.py:117-183；app/retrieval.py:198-285；app/__init__.py:768-812, 1470-1577。

2. 绑定知识库后，是否每轮发送全部内容？

否。会话先按班级和智能体绑定的 material_ids 执行关键词/向量融合检索，最多给出 5 个候选；若技能指定“资料”，再按材料标题过滤，最终最多 4 个有效片段进入本轮 user 消息，每片最多 800 字。独立 AI 资料问答最多 5 片，每片最多 800 字、片段正文合计最多 4000 字；无证据时不调用聊天模型。向量检索可能单独向 Embeddings 接口发送问题文本。

代码依据：app/__init__.py:1498-1521；app/retrieval.py:640-661, 710-774；app/tutoring.py:21-22, 144-162。

3. 绑定 Skill 后，是否每轮发送全部内容？

否。仅从当前会话已选、智能体已绑定且仍启用的技能中，按本轮问题包含的触发词确定性计分，最多选择一项。模型仅收到该技能名称、description 及少量固定规则；source_text 中完整元数据、适用条件、资料字段和工具清单不原样传递。未命中时没有技能说明。

代码依据：app/tutoring.py:34-114, 117-183；app/__init__.py:1390-1400, 1478-1521。

4. Skill 执行逻辑

教师上传 UTF-8 单文件或提交 source_text；元数据与说明须用空行分隔。解析器校验名称、适用条件、启用、长度及工具引用，持久化原文与结构化字段。新会话默认加载智能体开放且启用的技能，用户可改选或清空。每轮按触发词命中数选最高分技能，平分按较小 id。服务器先执行其 MCP 工具，再检索绑定资料，最后拼装消息请求 LLM。knowledge_search 在工具执行循环中被跳过，材料检索由会话流程独立执行；Skill 说明是提示词，不是可执行脚本。

代码依据：app/tutoring.py:34-114；app/__init__.py:1213-1261, 1347-1374, 1401-1441, 1478-1521。

5. 集成 MCP 后，每轮给 LLM 的内容

连接时服务端以 Bearer 令牌向 /mcp 发送 JSON-RPC 2.0 initialize（protocolVersion=2025-03-26、capabilities、clientInfo），然后 tools/list 并缓存工具 schema。问题命中含 tool@server 的 Skill 时，服务端发 tools/call，params 固定为 {name: 工具名, arguments: {question: 本轮完整问题}}。成功文本先在 MCP 客户端截为最多 4000 字，再截为最多 1000 字，以“外部数据”标记加入 LLM 的 user 消息；失败/拒绝仅返回状态并记录审计。LLM 请求仍只有 model/messages/temperature/max_tokens/stream，模型不能自行选择工具；外部工具也未按任意 inputSchema 自动组参。

代码依据：app/mcp_client.py:63-140；mcp-server/app.py:13-34, 73-110；app/__init__.py:1080-1117, 1401-1441；app/tutoring.py:157-162。

三、验证结果与当前限制

在临时 Python 3.12 环境安装 requirements.txt 后运行完整 pytest：46 passed in 3.62s。测试使用 fake 模型/检索客户端与临时数据库，不证明真实模型网关、MySQL、Qdrant 或容器联调。离线捕获的会话模型请求键为 model/messages/temperature/max_tokens/stream。模拟模型流输出“测试回复”后，应用测试客户端实际收到 HTTP 200 与 meta → delta → error，没有 done。

已确认缺陷：OpenAIChatClient.stream_messages 正常读完非空响应后仍无条件抛 AIAnswerUnavailable；上层会把成功输出后的结束误报为中断。当前提交保留了此缺陷，建议删除正常结束后的抛错并补充回归测试。

本机没有 docker 命令，不能在此完成容器端到端验证。部署机器应安装并启动 Docker Desktop/Compose V2，依据 .env.example 设置仅存本机的真实网关和密钥，运行 docker compose config --quiet、docker compose up --build -d、docker compose ps，并检查四个服务及 http://localhost:8000/health。若不用 Docker，仍须另行提供 MySQL、Qdrant 与兼容模型服务。

代码依据：app/retrieval.py:263-285；app/__init__.py:1535-1571；compose.yaml:1-93；docs/运行说明.md:1-22。

结论：该代码提交提供了可复核的核心实现与自动化测试；提示词模板和通用 MCP 能力仍有范围限制，真实容器/模型联调尚待完成。仓库地址和受检提交可供项目评审定位代码，本 PDF 记录了验证方法、结果及缺陷。